IBMEC
Instituto Brasileiro de Mercado de Capitais

EXTRAÇÃO E PREPARAÇÃO DE DADOS — TRABALHO INDIVIDUAL AP1

Crise do Banco Master:

Pipeline de Extração e Análise de Dados para a Linha do Tempo BSLI4

ALUNO: **Nicholas Borges de Vasconcelos**

MATRÍCULA: **202407138829**

DISCIPLINA: **Extração e Preparação de Dados**

PROFESSOR: **Prof. Alvaro Barros**

DATA DE ENTREGA: **Abril 2026**

Sumário

Sumário 2
1. Visão Geral do Trabalho 3
2. Recorte Individual 3
3. Pergunta Analítica Individual 4
4. Extração de Dados 4
4.1 Fonte dos Dados 4
4.2 Tipo de Fonte 4
4.3 Como a Extração foi Feita 5
5. Preparação dos Dados 6
5.1 Problemas Encontrados 6
5.2 Tratamentos Realizados 6
5.3 Justificativas 7
6. Estrutura Final dos Dados 7
6.1 Variáveis Utilizadas 7
6.2 Tipos de Dados 8
6.3 Variável Alvo Potencial 8
7. Limitações 8
7.1 Problemas nos Dados 8
7.2 Limitações da Análise 9
7.3 Possíveis Vieses 9
8. Proposta de Melhoria 9
8.1 O que Faria Diferente 9
8.2 Como Melhoraria a Coleta de Dados 10
Referências 11

1. Visão Geral do Trabalho

O trabalho investigou o impacto da crise do Banco Master sobre os preços e volumes das ações do BRB — Banco de Brasília (BSLI4.SA) — no período de março de 2025 a março de 2026. A pergunta central foi: em que medida os grandes eventos da crise — o veto do BACEN, a Operação Compliance Zero, a liquidação extrajudicial e a prisão de Daniel Vorcaro — determinaram as variações de preço e volume do BSLI4?

O objetivo foi construir um pipeline completo de extração e preparação de dados combinando séries quantitativas de mercado (Yahoo Finance/*yfinance*) com dados qualitativos extraídos de notícias e comunicados regulatórios, gerando uma linha do tempo interativa que correlacionasse eventos com variações de preço. O projeto foi desenvolvido individualmente com auxílio do Claude.ai. Por não ter conhecimento prévio sobre o Banco Master, a linha do tempo serviu também como ferramenta de compreensão da própria crise.

2. Recorte Individual

Por ter desenvolvido o projeto integralmente de forma individual, todas as etapas foram executadas por mim. A parte que analiso em maior profundidade neste relatório é o pipeline de extração e ingestão de dados textuais — compreendendo a detecção automática de picos no dataset de mercado, o scraping de artigos jornalísticos, a segmentação em chunks vetorizados no ChromaDB e a extração estruturada de eventos via RAG com Mistral 7B rodando localmente.

Escolhi esse recorte porque ele ocupa a posição crítica do pipeline: qualquer erro nessa cadeia — URL inválida, chunk mal segmentado ou embedding gerado sobre conteúdo irrelevante — propaga-se diretamente para a qualidade dos eventos extraídos e compromete a fidedignidade da visualização final. É também a etapa onde enfrentei os problemas mais concretos e onde as decisões de design tiveram o maior impacto observável no produto final.

3. Pergunta Analítica Individual

A pergunta analítica específica que orienta este relatório é:

> *"Quais eventos determinaram os picos detectados no BSLI4? É possível prever a direção do BSLI4 em T+1, usando notícias e artigos financeiros?"*

A pergunta é clara, respondível com os dados do projeto e possui impacto analítico direto: sua resposta explica por que certos eventos aparecem na linha do tempo com datas imprecisas ou descrições equivocadas, e orienta quais melhorias são prioritárias em uma versão futura do pipeline.

4. Extração de Dados

4.1 Fonte dos Dados

- **Dados quantitativos de mercado:** Yahoo Finance, acessado via biblioteca Python *yfinance*. Série histórica diária de BSLI4.SA (close, open, high, low, volume) para o período de março de 2025 a março de 2026.
- **Dados qualitativos textuais:** portais financeiros e regulatórios — Infomoney, Valor Econômico, Folha de S.Paulo, Banco Central do Brasil (bcb.gov.br), CVM — com descoberta de URLs via endpoint público Google News RSS (sem chave de API).

4.2 Tipo de Fonte

- **API Python gratuita (*yfinance*):** abstração sobre a API pública do Yahoo Finance, retornando dados OHLCV em DataFrame pandas.
- **Endpoint público RSS (Google News):** feed XML com links de notícias indexadas pelo Google, utilizável sem autenticação.
- **Web scraping (HTML → Markdown):** acesso direto às páginas de artigos via Playwright (Chromium headless), com conversão do HTML para Markdown via markdownify.

4.3 Como a Extração foi Feita

O pipeline de extração de eventos de mercado foi estruturado em oito etapas sequenciais:

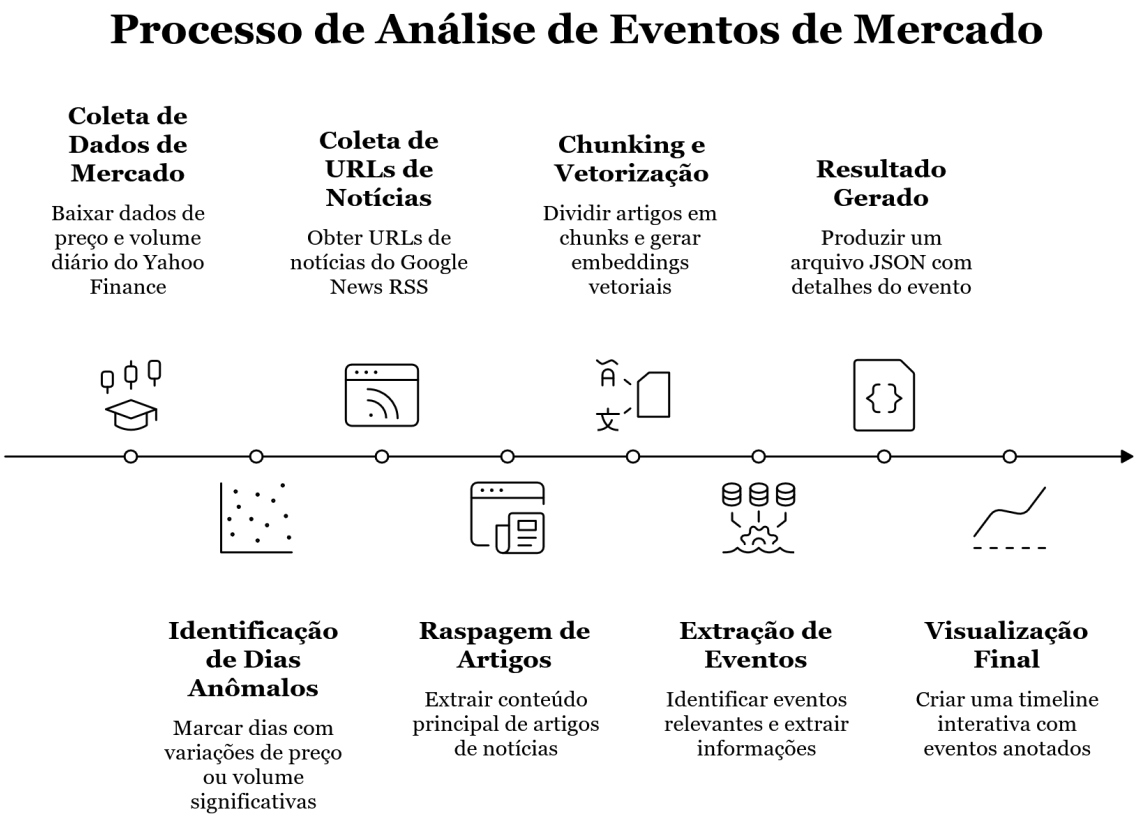

Etapa 1: Coleta dos dados de mercado — *yfinance* baixa 365 dias de preço e volume diário do BSLI4 direto do Yahoo Finance.

Etapa 2: Identificação dos dias anômalos — *harvest_urls.py* varre esses dados e marca os 24 pregões onde o preço variou ±5% ou o volume triplicou. Essas datas guiam todo o restante do pipeline.

Etapa 3: Coleta de URLs de notícias — Para cada data marcada, o Google News RSS é consultado em português e inglês, retornando URLs ranqueadas por fonte — priorizando Infomoney, Valor Econômico e BCB.

Etapa 4: Raspagem dos artigos — *scraper.py* abre cada URL com um navegador headless, remove ruídos como menus de navegação e banners de cookies, e salva o conteúdo principal como arquivo Markdown.

Etapa 5: Chunking e vetorização — ingest.py divide cada arquivo Markdown em pedaços de ~500 tokens, gera um embedding vetorial para cada chunk e armazena tudo no ChromaDB.

Etapa 6: Extração de eventos — query.py busca os chunks mais relevantes no ChromaDB, remove duplicatas por hash, e envia o contexto consolidado para o modelo Mistral 7B local com instrução para retornar apenas JSON estruturado.

Etapa 7: Resultado gerado — O modelo produz o *events.json*, onde cada registro contém data, título do evento, categoria, sentimento e a variação de preço do BSLI4 naquele dia.

Etapa 8: Visualização final — Os dados de mercado e os eventos são combinados em uma timeline interativa em React + Recharts, onde cada evento aparece como um marcador anotado sobre a curva de preço do BSLI4.

5. Preparação dos Dados

5.1 Problemas Encontrados

Dados faltantes e inconsistentes: Em datas de feriados da B3, os registros de mercado estavam ausentes ou com volume zero. Em certos períodos, a yfinance retornava colunas com MultiIndex — comportamento inconsistente entre versões da biblioteca que exigiu tratamento explícito.

Qualidade das fontes textuais: Muitas URLs coletadas retornavam paywalls ou páginas de erro que foram convertidas em Markdown de baixíssima qualidade — frequentemente apenas título e linha de assinatura — e ingeridas no ChromaDB junto com material válido, contaminando a base vetorial. O Google News RSS também apresentou dificuldades de cobertura temporal para eventos mais antigos.

Duplicidades: Sem controle explícito, o mesmo artigo poderia aparecer em múltiplas consultas RSS e ser ingerido mais de uma vez no ChromaDB com pequenas variações de texto, inflando artificialmente o peso de certos conteúdos na recuperação semântica.

5.2 Tratamentos Realizados

Nos dados de mercado (*data_pipeline.py*):

- **Alinhamento ao calendário B3:** reindexação com pandas_market_calendars (calendário BMF) e forward fill estrito para preencher feriados sem interpolação.
- **Normalização de MultiIndex:** detecção e extração automática do primeiro nível de colunas quando o yfinance retornava MultiIndex.
- **Criação de variáveis derivadas:** SMA_7, SMA_30 (médias móveis de fechamento) e Volatility_30 (desvio-padrão dos retornos diários × √252).
- **Serialização JSON:** conversão de NaN para 0 e exportação em formato orientado a registros para compatibilidade com o frontend React.

Nos dados textuais:

- **Remoção de ruído no HTML:** seletores CSS configurados no scraper para eliminar navegação, cabeçalhos, rodapés, banners, scripts e estilos antes da conversão.
- **Filtragem por tamanho mínimo:** documentos com menos de 100 caracteres após o scraping foram descartados automaticamente.
- **Saída JSON forçada:** o prompt de sistema especificava saída exclusivamente em JSON estruturado, seguindo schema definido — sem prosa livre ou fences de código Markdown.

5.3 Justificativas

O forward fill foi escolhido porque preserva a realidade do mercado: na ausência de negociação, o preço efetivo permanece o último fechamento disponível. A interpolação criaria valores artificiais sem embasamento nos dados observados.

O tamanho de chunk de 500 tokens foi calibrado empiricamente: chunks menores perdiam contexto causal necessário para o modelo inferir a relevância do evento; chunks maiores excediam a janela efetiva do Mistral 7B com offload parcial de camadas na CPU, degradando a coerência das extrações.

O formato JSON forçado foi necessário porque, sem essa instrução, o Mistral 7B alternava entre prosa livre e JSON, tornando o parser frágil. A restrição aumentou a consistência das saídas ao custo de pequena redução na riqueza descritiva.

6. Estrutura Final dos Dados

6.1 Variáveis Utilizadas

Dataset de mercado — *brb_market_data.json* (265 registros diários):

name	type	description
date	string (YYYY-MM-DD)	data do pregão
close, open, high, low	float	preços OHLC em BRL
volume	int	contratos negociados
sma_7, sma_30	float	médias móveis simples de 7 e 30 dias sobre o fechamento
volatility_30	float	volatilidade anualizada de 30 dias

Dataset de eventos — *events.json* (21 registros):

Name	Type	Description
date	string	Data do evento
title_en, title_pt	string	Título bilíngue (máx. 8 palavras)
description_en, description_pt	string	Descrição factual de 1–2 frases
category	enum	regulatory | legal | market | fraud | governance | arrest
sentiment	enum	bullish | bearish | neutral | crisis
bsli4_change_pct	float | null	Variação percentual das ações na data
price_bsli4	float | null	Preço de fechamento do BSLI4 na data do evento
sources	array	Arquivos-fonte utilizados na extração RAG

6.2 Tipos de Dados

O projeto utilizou uma abordagem híbrida de dados: informações quantitativas, como preços (float), volumes (int) e indicadores técnicos (SMA e volatilidade), foram extraídas de fontes de mercado; e dados qualitativos, como títulos e descrições factuais (string), categorias (enum) e sentimentos (enum), foram obtidos via extração RAG de portais financeiros e regulatórios.

6.3 Variável Alvo Potencial

A variável bsli4_change_pct — variação percentual diária do BSLI4 — seria a candidata natural a variável alvo em um modelo preditivo ou analítico. O interesse seria prever a magnitude e o sinal da reação do mercado a partir da category e do sentiment do evento. Alternativamente, peak_flag poderia ser usada como target de classificação binária para identificar pregões com movimentação anormal.

7. Limitações

7.1 Problemas nos Dados

Embora o dataset quantitativo de mercado existente não tenha apresentado problemas de consistência ou qualidade intrínseca, sua limitação reside no escopo temporal — só pegamos dados de março de 2025 até o presente – março 2026. Para

projetos futuros, a adição de dados de outros bancos de porte semelhante seria valiosa para uma análise comparativa mais robusta.

Nas fontes textuais, artigos com paywall foram processados e convertidos em Markdown mínimo antes de serem ingeridos no ChromaDB junto com material válido. Sem filtro de qualidade baseado em densidade semântica, esses chunks contaminaram a base vetorial e reduziram a precisão da recuperação. Houve a necessidade de muitas alterações manuais para cada chunk criado, visto que cada website tinha seu próprio estilo de escrita, e, portanto, nenhuma única expressão regular, regex, pôde remover todos os dados do markdown necessários.

7.2 Limitações da Análise

A principal limitação analítica é a ausência de ground truth: sem linha do tempo de referência construída manualmente, não há como calcular métricas objetivas de precision e recall para os eventos extraídos pelo RAG. A validação foi essencialmente visual e subjetiva.

O Mistral 7B local apresentou taxa de alucinação não desprezível: datas foram confundidas entre artigos do mesmo mês, eventos distintos foram mesclados em um único registro, e campos numéricos como bsli4_change_pct foram preenchidos com valores plausíveis mas factualmente incorretos. A janela de contexto efetiva com offload de camadas na CPU foi outro limitante prático.

7.3 Possíveis Vieses

Viés de cobertura: as fontes priorizadas pelo sistema de pontuação de URLs têm cobertura concentrada em eventos de grande repercussão, podendo subrepresentar eventos regulatórios menores que também movimentaram o mercado.

Viés de disponibilidade temporal: artigos publicados em datas onde as URLs expiraram ou foram removidas antes do scraping ficaram sem cobertura textual. Como o Google News RSS indexa apenas as últimas semanas, eventos mais antigos dependiam de URLs fixas inseridas manualmente.

8. Proposta de Melhoria

8.1 O que Faria Diferente

A principal mudança estrutural seria expandir o escopo do projeto para incluir outros bancos de porte semelhante ao Banco Master que estiveram operando no

mesmo período. A análise atual isola o BSLI4 como único objeto de estudo, o que limita a capacidade de distinguir movimentos causados especificamente pela crise do Banco Master daqueles que refletem o comportamento sistêmico do setor financeiro brasileiro como um todo.

Com uma cesta comparativa — incluindo, por exemplo, bancos médios listados na B3 com perfil de risco e capitalização similares — seria possível identificar se os picos de volume e variação de preço do BSLI4 foram idiossincráticos ou se outros papéis do setor reagiram de forma semelhante nos mesmos pregões. Essa comparação tornaria a análise causal mais robusta: um evento que moveu apenas o BSLI4 é um sinal muito mais forte de causalidade direta do que um evento que moveu todo o setor simultaneamente.

Do ponto de vista técnico, a expansão exigiria adaptações relativamente pequenas no pipeline existente — o yfinance já suporta múltiplos tickers, e o frontend em Recharts comporta múltiplas séries sobrepostas — mas agregaria valor analítico substancial à visualização final.

8.2 Como Melhoraria a Coleta de Dados

Em vez de depender do Google News RSS como mecanismo principal de descoberta de artigos, construiria uma curadoria manual de fontes antes de iniciar o scraping. Isso significaria identificar previamente os artigos mais relevantes para cada evento-chave, priorizando portais que não impõem paywall — como o próprio site do Banco Central, a CVM, e veículos que disponibilizam conteúdo aberto. A curadoria manual tem um custo de tempo maior, mas elimina dois dos problemas mais impactantes do pipeline atual: a ingestão de páginas de erro e conteúdo mínimo no ChromaDB, e a cobertura temporal desigual causada pela janela curta de indexação do RSS.

Além disso, testaria sistematicamente variações no pipeline de RAG para mitigar a taxa de alucinação do modelo. As três dimensões prioritárias seriam: o método de chunking — testando sobreposição (overlap) entre chunks para preservar contexto causal que atualmente se perde nas fronteiras de segmentação; o modelo de embedding — comparando o *mxbai-embed-large* com alternativas como *nomic-embed-text*, que apresenta melhor desempenho em textos financeiros em português; e o próprio modelo de extração — substituindo o Mistral 7B por uma opção com menor taxa de alucinação em geração de JSON estruturado, como o Claude Haiku via API, que oferece saída mais consistente a custo controlado para o volume de dados deste projeto. Como não havia ground truth para medir o impacto de cada mudança, iterações cegas sobre esses parâmetros não resolveriam o problema de forma

sistemática — o que reforça também a necessidade de construir um dataset de referência manual, conforme descrito na seção anterior.

Referências

Para mais informações sobre o projeto ou para interagir com a linha do tempo:

- **Repositório do Projeto (GitHub):** Acesse o Código no GitHub
- **Aplicação Interativa (Vercel):** Interaja com a Linha do Tempo