EXTRAÇÃO E PREPARAÇÃO DE DADOS

Relatório de Projeto

Crise Banco Master e o Impacto no BRB – Banco de Brasília

(BSLI3 / BSLI4)

Análise Cronológica de Eventos e Impacto no Mercado de Capitais

Aluno Nicholas Borges de Vasconcelos	**Professor** Prof. Alvaro Barros
Matricula 202407138829	**Disciplina** Extração e Preparação de Dados

1. Definição do Objeto de Investigação

Este projeto investiga o impacto da crise do Banco Master sobre as ações do Banco de Brasília (BRB), negociadas na B3 sob os tickers BSLI3 (ações ordinárias) e BSLI4 (ações preferenciais), no período compreendido entre agosto de 2025 e março de 2026 — intervalo em que os dados históricos de mercado se encontram disponíveis.

A investigação concentra-se em três dimensões inter-relacionadas:

- Impacto nos preços: como cada grande evento da crise (anúncio da aquisição, veto do BACEN, Operação Compliance Zero, prisão de Vorcaro, plano de recapitalização) se refletiu em variações percentuais no fechamento diário das ações BSLI3 e BSLI4;
- Anomalias de volume: identificação de pregões com volume de negociação anormalmente elevado — indicador de que o mercado já processava informações relevantes antes ou durante a divulgação oficial dos fatos;
- Eventos não explicados: mapeamento de oscilações significativas (acima de ±5%) que ocorreram nos períodos de setembro–outubro de 2025 e nos dias 5–6 e 28 de novembro de 2025, para os quais ainda não há causa publicamente documentada, sugerindo possível vazamento de informações ou reações a comunicados não amplamente divulgados.

Escopo temporal dos dados de mercado disponíveis

Período	Evento Âncora	Dados Disponíveis
Ago 2025	Aprovação CLDF / submissão ao BACEN	Sim
Set 2025	Veto do BACEN (3 Set) e reação de mercado	Sim
Out–Nov 2025	Gaps inexplicados e Operação Compliance Zero	Sim
Nov–Dez 2025	Liquidação extrajudicial do Banco Master	Sim
Jan–Mar 2026	Choque do plano de capital / re-prisão de Vorcaro	Sim
Mar–Mai 2025	Anúncio inicial da aquisição (pico de +83%/+90%)	Sim

2. Pergunta Central de Análise

Pergunta	Em que medida os grandes eventos institucionais, regulatórios e jurídicos da crise do Banco Master determinaram as variações de preço e de volume das ações BSLI3 e BSLI4 entre agosto de 2025 e março de 2026, e é possível prever a direção do movimento do ativo no pregão seguinte a partir de indicadores quantitativos extraídos dos próprios dados históricos?

3. Justificativa e Relevância do Tema

3.1 Relevância financeira e histórica

A crise do Banco Master é considerada **o maior escândalo bancário da história recente do Brasil**, com um rombo estimado em R$ 12,2 bilhões em carteiras de crédito supostamente fraudulentas vendidas ao BRB entre janeiro e maio de 2025. A liquidação extrajudicial decretada pelo BACEN em 18 de novembro de 2025 afetou diretamente os ativos do BRB, banco público controlado pelo Governo do Distrito Federal, expondo os riscos de governança em aquisições de instituições privadas por bancos estatais.

3.2 Relevância para a disciplina

Do ponto de vista da Extração e Preparação de Dados, o caso apresenta desafios concretos e pedagogicamente relevantes:

- Coleta automatizada de dados financeiros históricos via API (Yahoo Finance / B3);
- Scraping de notícias em múltiplas fontes heterogêneas (portais de notícias, PDFs de comunicados regulatórios, RSS do Google News) para construção de um corpus documental;
- Construção de um pipeline de RAG (Retrieval-Augmented Generation) com modelos locais (Ollama + ChromaDB) para extração estruturada de eventos em formato JSON;
- Identificação e tratamento de dados faltantes — o dataset disponível inicia em agosto de 2025, perdendo o pico de +83%/+90% registrado em 31 de março de 2025;
- Detecção de anomalias (picos de preço e volume) por métodos quantitativos simples sobre séries temporais financeiras.

3.3 Relevância para o mercado de capitais brasileiro

O BSLI4 acumulou uma queda de aproximadamente 82% desde o pico atingido em 31 de março de 2025 (R$ 24,50) até março de 2026 (R$ 4,21), destruindo valor de mercado de ordem superior a R$ 7 bilhões. A análise da correspondência entre eventos e movimentos de preço tem valor tanto para investidores — que podem calibrar melhor o risco de eventos regulatórios — quanto para reguladores e pesquisadores interessados em eficiência informacional do mercado acionário brasileiro.

4. Identificação das Fontes de Dados

4.1 Dados quantitativos de mercado

Fonte	Conteúdo	Formato	Acesso
Yahoo Finance (yfinance)	Preços OHLCV diários BSLI4.SA	JSON / CSV	API Python gratuita
B3 – Brasil Bolsa Balcão	Histórico oficial de negociações	CSV	Portal público
Dataset fornecido	239 pregões (Ago 2025 – Mar 2026)	JSON	Fornecido diretamente

4.2 Dados qualitativos — fontes de notícias

Fonte	Tipo	Relevância
Infomoney.com.br	Portal financeiro	Cobertura diária de BSLI3/BSLI4
Valor Econômico	Jornal especializado	Cobertura regulatória e institucional
Folha de S.Paulo / O Globo	Imprensa geral	Eventos de grande repercussão
Banco Central do Brasil (bcb.gov.br)	Regulador oficial	Comunicados de liquidação e rejeição
CVM (cvm.gov.br)	Regulador de capitais	Fatos relevantes do BRB
Covington & Burling (fev. 2026)	Relatório jurídico internacional	Visão consolidada da crise
Google News RSS	Agregador	Descoberta automática de URLs por data

4.3 Dados institucionais

- Fatos relevantes publicados pelo BRB na CVM (formulários de Material Fact);
- Atas de aprovação da CLDF (PL 1.882/2025, sancionado em 20 de agosto de 2025);
- Despacho de rejeição do BACEN (3 de setembro de 2025);
- Decretos de liquidação extrajudicial do Banco Master (18 de novembro de 2025).

5. Extração dos Dados

5.1 Pipeline de extração — visão geral

O processo de extração foi estruturado em quatro etapas sequenciais, implementadas em Python e organizadas no projeto brb-rag:

Etapa 1 — Detecção automática de picos no dataset

O script harvest_urls.py lê o arquivo brb_market_data.json (239 registros diários) e calcula, para cada pregão, a variação percentual de fechamento em relação ao dia anterior. Registros com $|\Delta P| \geq 5\%$ ou volume ≥ 3× a média do dia anterior são sinalizados como picos de interesse. Foram identificados 24 eventos relevantes.

Etapa 2 — Coleta automatizada de URLs por data

Para cada data de pico identificada, o script executa de 4 a 6 consultas distintas ao endpoint público do Google News RSS (news.google.com/rss/search), em português e inglês. As URLs retornadas são pontuadas por domínio (priorizando Infomoney, Valor, Estadão, Reuters, BCB) e filtradas por relevância temática. O resultado é gravado automaticamente em scraper/urls.txt com cabeçalhos de data e contexto.

Etapa 3 — Scraping do conteúdo

O script scraper/scrape.py utiliza o Playwright (navegador Chromium em modo headless) para acessar cada URL, remover elementos de ruído (navegação, rodapé, banners de cookies) e converter o conteúdo principal em Markdown via markdownify. Cada arquivo é salvo em raw_docs/ com metadado source_url no cabeçalho YAML. O processo é incremental — URLs já processadas são ignoradas em re-execuções.

Etapa 4 — Ingestão na base vetorial

O script ingest.py divide cada documento Markdown em chunks de ~500 tokens com sobreposição de 75 tokens (RecursiveCharacterTextSplitter do LangChain), gera embeddings via modelo nomic-embed-text (Ollama local, CPU) e armazena os vetores no ChromaDB persistente (pasta chroma_db/). O processo é incremental: arquivos já embutidos são identificados pelo metadado source_file e ignorados.

5.2 Especificações técnicas do ambiente de extração

Componente	Ferramenta / Versão	Função
LLM local	Mistral 7B Instruct Q4_K_M (Ollama)	Extração estruturada de eventos
Modelo de embeddings	nomic-embed-text (Ollama)	Vetorização dos chunks
Base vetorial	ChromaDB 0.5.15	Armazenamento e busca semântica
Scraper	Playwright 1.47 + markdownify 0.13	Coleta de conteúdo web
Chunking	LangChain RecursiveCharacterTextSplitter	Segmentação dos documentos
GPU	NVIDIA GTX 1080 Ti (11 GB VRAM)	Inferência do LLM
RAM	48 GB DDR4	Offload de camadas do modelo

6. Preparação dos Dados

6.1 Dados quantitativos

O arquivo brb_market_data.json foi recebido com os campos Date, Open, High, Low, Close, Volume, SMA_7, SMA_30 e Volatility_30 já parcialmente calculados. As seguintes transformações adicionais foram aplicadas:

- Cálculo de variação diária (pct_change): $\Delta P(t) = (Close(t) - Close(t-1)) / Close(t-1) \times 100$, com tratamento de divisão por zero para o primeiro registro;
- Razão de volume (vol_ratio): Volume(t) / Volume(t−1), usada como proxy de interesse institucional incomum no pregão;
- Amplitude intradiária (%): (High − Low) / Low × 100, indicador de incerteza e volatilidade intraday;
- Flag de pico: variável booleana (True quando $|\Delta P| \geq 5\%$ OU vol_ratio ≥ 3 com $|\Delta P| \geq 2\%$);
- Tratamento de registros com High = 0 e Volume = 0 (dias sem negociação — 20 e 23 de março de 2026): excluídos das métricas que dependem de range e volume.

6.2 Dados qualitativos — pipeline RAG

Após a ingestão no ChromaDB, o script query.py executa 10 consultas de recuperação semântica distintas — cobrindo variações terminológicas em português e inglês para os principais eventos da crise. Os chunks recuperados são consolidados (deduplicação por hash dos primeiros 120 caracteres) e passados ao Mistral 7B com um prompt de sistema que exige saída exclusivamente em JSON estruturado, seguindo o schema:

Schema JSON de eventos extraídos pelo RAG

Campo	Tipo	Descrição
date	string (YYYY-MM-DD)	Data do evento
title	string (máx. 8 palavras)	Título curto do evento
description	string (1–2 frases)	Descrição factual
bsli4_change_pct	float | null	Variação % do BSLI4 (null se não confirmada)
price_bsli4	float | null	Preço de fechamento do BSLI4
sentiment	enum	bullish | bearish | neutral | crisis
category	enum	regulatory | legal | market | fraud | governance | arrest
sources	array[string]	Arquivos markdown de origem

6.3 Fusão e curadoria final

O script generate_events.py executa a fusão entre os eventos extraídos pelo RAG e um arquivo events_manual.json pré-curado (16 eventos com datas, variações percentuais e categorias confirmadas a partir de fontes primárias). As regras de fusão são:

- Deduplicação: eventos com mesma data e primeiros 20 caracteres de título idênticos são mesclados, com preferência por campos não-nulos;
- Ordenação cronológica: saída final ordenada por date crescente;
- Enriquecimento: adição dos campos timestamp_ms (epoch em milissegundos para o eixo X do gráfico), sentiment_score (−2 a +1) e color (hex por categoria) para consumo direto pelo front-end.

O arquivo final output/events.json contém os campos gerados_at, total_events, schema_version e o array events, pronto para ser consumido pela aplicação de visualização sem nenhuma transformação adicional.

7. Criação da Exibição dos Dados

7.1 Concepção da visualização

A exibição dos dados foi concebida como uma linha do tempo interativa que sobrepõe a série histórica de preços do BSLI4 com anotações de eventos extraídos do pipeline RAG. O objetivo é permitir que o usuário compreenda visualmente a correspondência entre fatos institucionais e movimentos de mercado, com granularidade diária.

7.2 Componentes da visualização

- Gráfico de linha de preço (BSLI4 Close): eixo X em timestamp_ms, eixo Y em reais (R$), com tooltips mostrando Open/High/Low/Close/Volume por pregão;
- Marcadores de evento: anotações verticais posicionadas em timestamp_ms dos eventos, coloridas por categoria (azul = regulatório, roxo = jurídico, verde = mercado, laranja = governança, vermelho = prisão/fraude);
- Bandas de SMA-7 e SMA-30: exibidas como linhas secundárias para contextualizar tendência de curto e médio prazo;
- Painel de sentimento: indicador visual abaixo do gráfico principal mostrando sentiment_score (−2 a +1) por evento, permitindo leitura rápida do ambiente de mercado em cada período;
- Filtros interativos: seleção por categoria de evento e por período (slider de datas), com re-renderização dinâmica.

7.3 Tecnologia de implementação

A visualização é implementada como uma aplicação React de arquivo único (.jsx), utilizando a biblioteca Recharts para o gráfico de séries temporais. O arquivo output/events.json é consumido diretamente via fetch(), eliminando a necessidade de backend. Os eventos são renderizados como ReferenceLine com label customizado. A paleta de cores segue o sistema de design definido no pipeline (campo color de cada evento).

8. Escolha do Ponto Passível de Predição

Alvo preditivo	Direção do movimento do BSLI4 no pregão T+1: classificação binária UP (fechamento T+1 > fechamento T) ou DOWN (fechamento T+1 ≤ fechamento T).

8.1 Justificativa da escolha

A série histórica disponível apresenta 24 picos de relevância estatística e padrões recorrentes — como a sequência pico/reversão em 48 horas observada em 29–30 de setembro e 6–7 de outubro de 2025 — que sugerem previsibilidade de curto prazo condicionada à magnitude do movimento anterior. A classificação binária de direção (em vez de magnitude exata) reduz o problema à sua forma mais tratável, dada a limitação de apenas 239 observações.

8.2 Variáveis preditoras propostas

Variável	Cálculo	Hipótese
pct_change_t	ΔClose(t) / Close(t−1)	Reversão à média: grandes quedas tendem a ser seguidas de recuperação parcial
vol_ratio_t	Volume(t) / Volume(t−1)	Volume alto acompanhado de queda → maior probabilidade de continuação

Variável	Cálculo	Hipótese
intraday_range_t	(High − Low) / Low	Alta volatilidade intraday → incerteza → maior prob. de reversão
dist_sma7_t	(Close(t) − SMA7(t)) / SMA7(t)	Desvio da média móvel de 7 dias → força de reversão
dist_sma30_t	(Close(t) − SMA30(t)) / SMA30(t)	Tendência de médio prazo → momentum
volatility_30_t	Campo nativo do dataset	Regime de alta volatilidade → menor previsibilidade
event_flag_t	1 se evento no dia t, 0 caso contrário	Dias de evento têm comportamento distinto de dias normais
sentiment_score_t	−2 a +1 do events.json	Sentimento do evento âncora como proxy de fluxo institucional

8.3 Modelo sugerido e limitações

Dado o tamanho reduzido da amostra (239 observações, com apenas 24 dias de evento), o modelo inicial recomendado é uma Regressão Logística com regularização L2 — interpretável, robusta a overfitting em amostras pequenas e capaz de fornecer probabilidades calibradas. Um Random Forest com max_depth = 3 pode ser avaliado como alternativa, com validação cruzada temporal (TimeSeriesSplit) para evitar data leakage.

Limitação principal: os dados disponíveis iniciam em agosto de 2025, excluindo o período de maior variação do ativo (março–julho de 2025, quando o BSLI4 caiu de ~R$ 24,50 para ~R$ 9,73). A incorporação desse período — mediante obtenção do histórico completo via yfinance — é fortemente recomendada antes de qualquer tentativa de treinar um modelo com capacidade preditiva real.

Resumo Executivo

Seção	Síntese
Objeto de investigação	Impacto da crise do Banco Master nos preços e volumes das ações BSLI3/BSLI4 (Ago 2025 – Mar 2026)
Pergunta de análise	Quais eventos determinaram os 24 picos detectados? É possível prever a direção de T+1?
Relevância	Maior escândalo bancário do Brasil; queda de ~82% no BSLI4; desafios técnicos concretos de extração e RAG
Fontes de dados	Yahoo Finance / B3 (quantitativo) + Google News RSS + portais financeiros + documentos regulatórios (qualitativo)
Extração	Pipeline: detect spikes → harvest_urls → scrape → ingest (ChromaDB) → query RAG (Mistral 7B)
Preparação	Cálculo de ΔP, vol_ratio, flags; chunking 500 tokens; extração JSON estruturada; fusão com eventos manuais
Visualização	Timeline interativa React/Recharts: preço + anotações de eventos + filtros por categoria e período
Predição	Classificação binária UP/DOWN T+1 via Regressão Logística com 8 variáveis preditoras quantitativas e de evento